

گزارش فاز اول پروژه درس هوش مصنوعی

Retrieval-Augmented Generation and the Study of Hallucination

تولید تقویت شده با بازیابی و بررسی Hallucination

کد موضوع: T-05

نام دانشجو/اعضای گروه: پرهام شعبانی 9927683

نام استاد: دکتر کوهزادی

نیم سال: بهار ۱۴۰۴-۱۴۰۵

تاریخ: [1405/05/20]

چکیده

مدل های زبانی می توانند پاسخ هایی روان و قانع کننده تولید کنند، اما روان بودن پاسخ الزاماً به معنی درست بودن آن نیست. گاهی مدل در نبود اطلاعات کافی، جزئیاتی را تولید می کند که در منبع وجود ندارند. این رفتار «توهم» نامیده می شود. در این پروژه موضوع تولید تقویت شده با بازیابی یا RAG انتخاب شده است. در این روش، پیش از تولید پاسخ، یک بازیاب چند متن مرتبط را از میان مجموعه اسناد پیدا می کند و آن ها را همراه پرسش به مدل مولد می دهد. هدف این است که پاسخ مدل به شواهد واقعی متصل شود و منشأ خطا قابل بررسی باشد.

پرسش اصلی پروژه این است که یک خط لوله سبک RAG با استفاده از مدل های از پیش آموزش دیده تا چه اندازه می تواند متن مرتبط را پیدا کند، پاسخ مبتنی بر شواهد بسازد و در نبود پاسخ از تولید اطلاعات غیرمستند خودداری کند. مجموعه داده SQuAD 2.0 برای پروژه انتخاب شده است، زیرا هم پرسش های دارای پاسخ و هم پرسش های بدون پاسخ دارد. برای حفظ مقیاس مناسب پروژه، نمونه ای متوازن شامل ۱۰۰۰ پرسش در نظر گرفته شده است. بازیاب پایه `multi-qa-MiniLM-L6-cos-v1` و مولد پایه `FLAN-T5-small` است. در فاز اول، مسئله، داده، معماری خط پایه، معیارهای ارزیابی و برنامه تحلیل خطا تعریف و به صورت قابل تکرار در نوت بوک آماده شده اند. اجرای نهایی معیارها و نتیجه گیری تجربی متعلق به فاز دوم است و در این گزارش به عنوان نتیجه تکمیل شده ادعا نمی شود.

۱. مقدمه

مدل های زبانی از الگوهای موجود در داده های آموزشی خود برای تولید متن استفاده می کنند. این مدل ها پاسخ را مانند جست و جو در یک پایگاه داده برنمی گردانند، بلکه کلمه بعدی را بر اساس ورودی و دانش آماری خود پیش بینی می کنند. به همین دلیل ممکن است پاسخی از نظر نگارشی عالی اما از نظر محتوایی نادرست تولید شود. این مشکل در کاربرد آموزشی مهم تر است، زیرا دانشجو ممکن است پاسخ مطمئن مدل را درست فرض کند.

RAG از دو جزء اصلی تشکیل می شود. جزء اول «بازیاب» است که متن های مرتبط با پرسش را پیدا می کند. جزء دوم «مولد» است که با استفاده از پرسش و متن های پیدا شده پاسخ می نویسد. این جداسازی یک مزیت مهم

دارد: اگر پاسخ نهایی غلط باشد، می توان بررسی کرد که آیا متن صحیح پیدا نشده یا اینکه متن صحیح در اختیار مولد بوده ولی مولد از آن درست استفاده نکرده است.

این پروژه با هدف ساخت یک محصول تجاری یا آموزش یک مدل بزرگ انجام نمی شود. هدف، ایجاد یک خط پایه کوچک، قابل فهم و قابل تکرار است تا رفتار آن با معیارهای ساده و نمونه های واقعی بررسی شود.

۲. تعریف دقیق مسئله

ورودی سامانه یک پرسش انگلیسی است. سامانه باید ابتدا سه متن مرتبط را از corpus بازیابی کند. سپس مدل مولد باید تنها بر اساس این متن ها پاسخی کوتاه تولید کند. اگر شواهد لازم در متن ها وجود نداشته باشد، خروجی مطلوب واژه unanswerable است.

خروجی کامل سامانه می تواند شامل موارد زیر باشد:

- پرسش ورودی
- شناسه و متن سه سند بازیابی شده
- امتیاز شباهت هر سند
- پاسخ نهایی مدل
- اطلاعات لازم برای بررسی اینکه پاسخ مستند بوده است یا خیر

پرسش های پژوهش به شکل زیر محدود شده اند:

1. آیا بازیاب می تواند متن منبع هر پرسش را در رتبه اول یا میان سه نتیجه اول قرار دهد؟
2. مدل مولد برای پرسش های پاسخ پذیر تا چه اندازه پاسخ مرجع را بازتولید می کند؟
3. مدل در پرسش های پاسخ ناپذیر تا چه اندازه به درستی از پاسخ دادن خودداری می کند؟
4. آیا خطای نهایی بیشتر از بازیابی ناموفق ناشی می شود یا از استفاده نامناسب مولد از شواهد؟
5. چه الگوهایی در خطاهای سامانه بیشتر دیده می شوند؟

۳. انواع خطای مورد بررسی: برای ساده و قابل توضیح نگه داشتن تحلیل، خطاها در چند گروه اصلی بررسی خواهند شد:

۳-۱. شکست بازیابی: متن صحیح در میان سه نتیجه اول قرار نمی گیرد. در این وضعیت مدل مولد احتمالاً اطلاعات کافی برای ساخت پاسخ درست ندارد.

۳-۲. توهم در نبود شواهد: پرسش پاسخ ناپذیر است یا شواهد کافی بازیابی نشده اند، اما مدل به جای اعلام unanswerable یک پاسخ قطعی می سازد.

۳-۳. نادیده گرفتن شواهد: متن صحیح بازیابی شده است، اما مدل پاسخ ناسازگار با آن تولید می کند. این خطا بیشتر به بخش تولید یا نحوه نوشتن prompt مربوط است.

۳-۴. عدم تطابق ظاهری پاسخ: ممکن است پاسخ از نظر معنایی قابل قبول باشد، اما به دلیل تفاوت نگارشی، کوتاه نویسی یا استفاده از عبارت مترادف با پاسخ مرجع تطابق کامل نداشته باشد. این موارد باید دستی بررسی شوند و نباید فوراً توهم محسوب شوند.

۳-۵. فروپاشی پاسخ های چندگانه: گاهی برای یک پرسش بیش از یک پاسخ قابل قبول وجود دارد، اما مدل فقط یک گزینه را با اطمینان زیاد بیان می کند یا چند پاسخ را با یکدیگر ترکیب می کند.

۴. مجموعه داده

مجموعه داده انتخابی SQuAD 2.0 است که از طریق Hugging Face Datasets دریافت می شود. این مجموعه داده برای پرسش و پاسخ مبتنی بر متن طراحی شده و هر ردیف آن دارای فیلدهایی مانند عنوان، متن زمینه، پرسش و پاسخ مرجع است.

دلیل انتخاب این است که SQuAD 2.0 برای مطالعه توهم مناسب است، زیرا بخشی از پرسش های آن عمداً پاسخ قابل استخراج از متن ندارند. بنابراین علاوه بر سنجش پاسخ صحیح، می توان سنجید که آیا مدل در نبود شواهد از ساخت پاسخ جلوگیری می کند یا خیر. همچنین داده عمومی، شناخته شده و قابل تکرار است.

۴-۳. نمونه گیری

برای حفظ محدوده مناسب پروژه، از بخش validation مجموعه داده استفاده می شود. ابتدا بر اساس خالی یا غیرخالی بودن فهرست پاسخ های مرجع، متغیر `is\_answerable` ساخته می شود. سپس با seed تصادفی ۴۲، تعداد ۵۰۰ پرسش پاسخ پذیر و ۵۰۰ پرسش پاسخ ناپذیر انتخاب می شود. این طراحی باعث می شود ارزیابی رفتار مدل در دو وضعیت متوازن باشد.

نمونه ۱۰۰۰ تایی با روش stratified split به دو بخش تقسیم می شود:

- مجموعه توسعه: ۲۰۰ پرسش برای بررسی اولیه و تنظیم فرایند.
- مجموعه آزمون: ۸۰۰ پرسش برای ارزیابی نهایی در فاز دوم.

ساخت corpus:

متن context ممکن است برای چند پرسش تکرار شده باشد. به هر متن یکتا یک context_id اختصاص داده می شود و نسخه های تکراری حذف می شوند. مجموعه متن های یکتا corpus بازیاب را تشکیل می دهد. در ادامه، وجود متن منبع تمام پرسش های توسعه و آزمون در corpus بررسی می شود تا ارزیابی بازیابی معتبر باشد.

۴-۵. فایل های داده

داده های آماده شده در قالب های زیر ذخیره می شوند:

- data/corpus.csv: متن های یکتا و شناسه آن ها
- data/development.jsonl: پرسش های مجموعه توسعه
- data/test.jsonl: پرسش های مجموعه آزمون

۵. Baseline پیشنهادی

۵-۱. بازیاب معنایی

مدل بازیابی `sentence-transformers/multi-qa-MiniLM-L6-cos-v1` است. این مدل برای کاربردهای پرسش و پاسخ و جست و جوی معنایی مناسب است. مدل هر پرسش و هر متن را به برداری عددی به نام `embedding` تبدیل می کند. متن ها و پرسش هایی که معنای نزدیک تری دارند، بردارهای نزدیک تری خواهند داشت.

تمام `embedding` ها نرمال می شوند و شباهت کسینوسی بین بردار پرسش و بردار متن ها محاسبه می شود. برای هر پرسش، سه متن با بیشترین امتیاز شباهت انتخاب می شوند. استفاده از `top_k=3` اجازه می دهد علاوه بر نتیجه اول، احتمال حضور متن صحیح در چند نتیجه ابتدایی نیز بررسی شود.

۵-۲. مولد پاسخ

مدل مولد `google/flan-t5-small` است. این مدل از پیش آموزش دیده و `instruction-tuned` است و بدون آموزش مجدد برای تولید پاسخ استفاده می شود. انتخاب نسخه `small` هزینه محاسباتی را پایین نگه می دارد و با هدف پروژه سبک هماهنگ است.

۵-۳. طراحی `prompt`

`prompt` شامل دستور، متن های بازیابی شده و پرسش است. مدل صریحاً راهنمایی می شود که :

- پاسخ را فقط از متن های داده شده استخراج کند

- پاسخ را کوتاه نگه دارد

- اگر شواهد کافی وجود نداشت، `unanswerable` تولید کند

به دلیل محدودیت طول ورودی `FLAN-T5`، تعداد `token` های `prompt` کنترل و متن های طولانی کوتاه می شوند. این کار از قطع شدن بخش پرسش یا دستور جلوگیری می کند.

۵-۴. سخت افزار و تکرارپذیری

کد در صورت وجود از `GPU` استفاده می کند و در غیر این صورت روی `CPU` اجرا می شود. `seed 42` برای نمونه گیری و تولید تنظیم شده است. تولید پاسخ بدون `sampling` انجام می شود تا اجرای دوباره تا حد ممکن خروجی یکسانی ایجاد کند. مدل ها آموزش داده یا `fine-tune` نمی شوند؛ تنها `inference` انجام می شود.

برای جلوگیری از ازدست رفتن خروجی در صورت قطع اتصال `Colab`، طراحی `checkpoint` در نوت بوک وجود دارد تا نتیجه پس از هر `batch` ذخیره و اجرای بعدی از همان نقطه ادامه داده شود.

۶. ارزیابی

۶-۱. معیارهای بازیابی

- `Recall@1`: نسبت پرسش هایی که متن منبع آن ها دقیقاً در رتبه اول قرار گرفته است.
- `Recall@3`: نسبت پرسش هایی که متن منبع آن ها در یکی از سه رتبه اول قرار گرفته است.

Mean Reciprocal Rank یا MRR : برای هر پرسش معکوس رتبه متن صحیح محاسبه می شود. قرار گرفتن متن صحیح در رتبه اول امتیاز ۱، رتبه دوم امتیاز ۰/۵ و رتبه سوم امتیاز تقریبی ۰/۳۳ دریافت می کند. سپس میانگین این امتیازها گزارش می شود.

۶-۲. معیارهای تولید

Exact Match: پس از یکسان سازی حروف، حذف نشانه گذاری و کلمات کم اهمیت، بررسی می کند که پاسخ مدل دقیقاً با پاسخ مرجع برابر است یا خیر.

Token-level F1: میزان هم پوشانی tokenهای پاسخ مدل و پاسخ مرجع را اندازه می گیرد. این معیار به پاسخ های تا حدی درست نیز امتیاز می دهد.

Unanswerable Refusal Accuracy: نسبت پرسش های پاسخ ناپذیری که مدل برای آن ها به درستی unanswerable تولید کرده است.

۶-۳. breakdown پیشنهادی

نتایج برای کل داده، پرسش های پاسخ پذیر و پرسش های پاسخ ناپذیر جداگانه گزارش می شوند. همچنین عملکرد مولد در دو وضعیت مقایسه خواهد شد:

- زمانی که متن صحیح در نتایج بازیابی وجود دارد.
- زمانی که متن صحیح در سه نتیجه اول وجود ندارد.

این مقایسه برای تشخیص سهم بازیاب و مولد در خطای نهایی ضروری است.

۷. برنامه تحلیل دستی خطا

در فاز دوم، تعدادی از پاسخ های غلط به صورت دستی خوانده خواهند شد. برای هر نمونه موارد زیر ثبت می شود:

- پرسش
- پاسخ مرجع
- پاسخ تولیدشده
- متن بازیابی شده
- وضعیت حضور متن صحیح در top-3
- برچسب اولیه خطا
- توضیح انسانی درباره علت خطا.

حداقل چند نمونه نماینده از شکست بازیابی، توهم در نبود شواهد و نادیده گرفتن شواهد انتخاب می شود. برچسب خردکار فقط برای پیدا کردن نمونه های نامزد استفاده خواهد شد و تصمیم نهایی با بررسی انسانی انجام می شود.

۸. ساختار و قابلیت تکرار پروژه

نوت بوک مراحل پروژه را به ترتیب اجرا می کند: اتصال به محل پروژه، نصب وابستگی ها، بارگیری داده، نمونه گیری، ساخت corpus، تقسیم داده، بارگیری بازیاب، ساخت embedding، اجرای retrieval، تعریف معیارها، بارگیری مولد، ساخت prompt، تولید checkpointدار، ارزیابی و دموی نهایی.

کتابخانه های اصلی عبارت اند از:

- datasets برای دریافت SQuAD 2.0
- pandas و numpy برای داده و محاسبات
- scikit-learn برای تقسیم stratified
- sentence-transformers برای retrieval معنایی
- transformers و torch برای تولید پاسخ
- matplotlib برای نمودارها

README بسیار ساده ای قبل از هر سلول قرار داده شده است تا هدف، ورودی و خروجی هر مرحله قابل فهم باشد.

۹. محدودیت های طراحی

1. corpus فقط از متن های نمونه انتخاب شده ساخته می شود و یک پایگاه دانش عمومی نیست.
2. تعداد نمونه ها برای کنترل هزینه محاسباتی محدود شده است.
3. FLAN-T5-small سبک است و ممکن است قدرت استدلال و پیروی از شواهد آن از مدل های بزرگ تر کمتر باشد.
4. Exact Match می تواند پاسخ درست با نگارش متفاوت را اشتباه محسوب کند.
5. وجود متن منبع در top-3 الزاماً به معنی وجود جمله دقیق پاسخ در بخش باقی مانده پس از کوتاه سازی prompt نیست.
6. برچسب گذاری خودکار خطا برای نتیجه گیری کافی نیست و به بررسی انسانی نیاز دارد.
7. نتایج این نمونه را نمی توان بدون آزمایش بیشتر به حوزه های تخصصی یا زبان فارسی تعمیم داد.

10. نتیجه گیری فاز اول

در فاز اول، موضوع T-05 به یک مسئله مشخص و قابل اجرا محدود شد. SQuAD 2.0 به عنوان داده عمومی مناسب انتخاب و روش نمونه گیری متوازن تعریف شد. یک baseline قابل تکرار با بازیاب Sentence Transformer و مولد FLAN-T5-small طراحی شد. معیارهای بازیابی، تولید و خودداری از پاسخ مشخص شدند و گروه های اولیه تحلیل خطا تعریف شدند. این طراحی امکان می دهد در فاز دوم عملکرد دو جزء retrieval و generation جداگانه بررسی شود.

۱۱. وضعیت کدهای مربوط به فاز دوم در پایان فاز اول

در نسخه فعلی نوت بوک، زیرساخت های زیر از قبل نوشته شده اند:

- اجرای retrieval روی مجموعه توسعه و آزمون
- محاسبه Recall@1، Recall@3 و MRR
- تولید پاسخ به صورت batch و checkpoint دار
- محاسبه Exact Match، F1 و دقت خودداری از پاسخ
- breakdown پاسخ پذیر/پاسخ ناپذیر و retrieval/generation
- ساخت نامزدهای اولیه برای گروه بندی خطا
- تولید فایل های CSV، JSONL و نمودارها
- تابع دموی ask_yadyar برای اجرای یک پرسش

وضعیت نهایی پروژه:

فاز اول کامل طراحی و پیاده سازی شده است؛ بخشی از کدهای مورد نیاز فاز دوم نیز آماده شده اند، اما فاز دوم هنوز به عنوان آزمایش و تحویل نهایی تکمیل نشده است.

منابع

1. Lewis, P. et al. (2020). *Retrieval-Augmented Generation for Knowledge-Intensive NLP Tasks*. NeurIPS.
2. Rajpurkar, P., Jia, R., & Liang, P. (2018). *Know What You Don't Know: Unanswerable Questions for SQuAD*. ACL.
3. Reimers, N., & Gurevych, I. (2019). *Sentence-BERT: Sentence Embeddings Using Siamese BERT-Networks*. EMNLP-IJCNLP.
4. Chung, H. W. et al. (2022). *Scaling Instruction-Finetuned Language Models*. arXiv.
5. Hugging Face. *Transformers, Datasets, and Sentence Transformers Documentation*.
6. YadYar Lite: Lightweight ML * داکيومنت نیازمندی های پروژه درس هوش مصنوعی، * Learning Assistant*، موضوع T-05.